


预备知识—概率论



- 概要
- 基本概念
- 随机变量与概率分布
- 数字特征

概率论的起源：赌注分配问题



求助

17世纪中叶，法国贵族梅耳骑士与人掷骰子赌博，赌注分配有歧义



帕斯卡



讨论

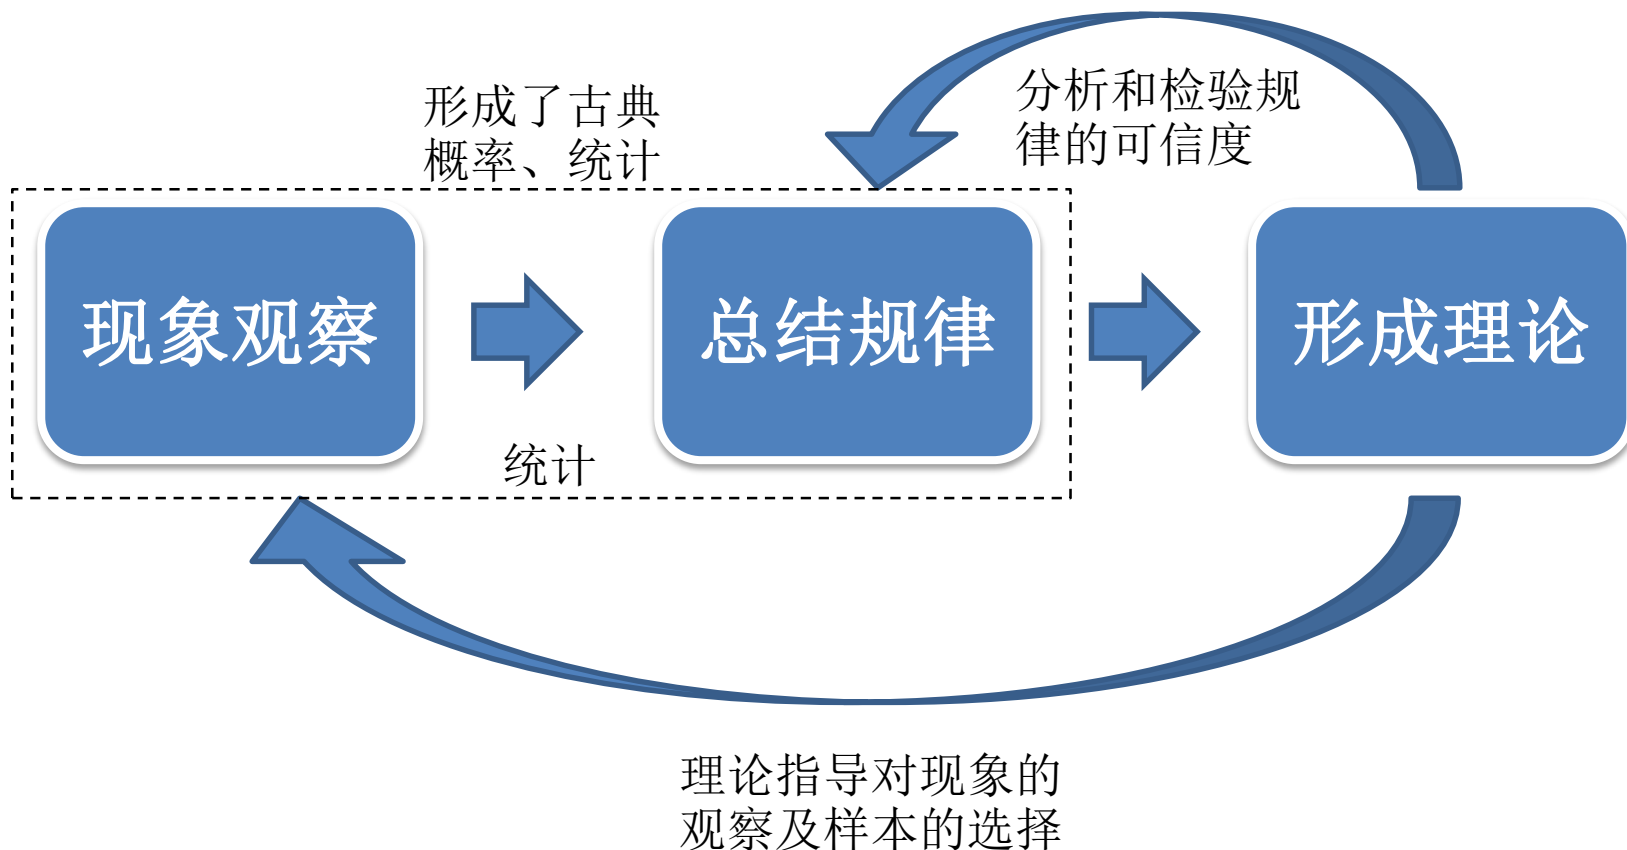


费马



最后由瑞士数学家雅各布·伯努利彻底证明该问题，提出**大数定理**，出版《猜度术》

概率论起源与发展



要点： 弄清统计与概率论之间的关系，避免混淆彼此概念

概率的几种解释

客观解释

- 又叫频率解释。概率描述了一个可以重复出现的事件的客观事实，用该事件发生的频率的极限来刻画

个人主义解释

- 也称为主观解释或贝叶斯解释，认为概率是某个人的偏好，它可以根据某人在带有不确定性结果的事件中表现出的行为来推算

必要性解释

- 又叫逻辑解释。此观点将概率视作命题与命题之间联系程度的度量，该联系程度是纯客观的，与人的作用无关，而是一种逻辑推理

随机试验

试验结果事先不能准确预言，三个特征

可以在相同条件下
重复进行

每次试验结果不止
一个，可预先知道
试验所有可能结果

每次试验前不能确
定那个结果会出现

样本空间

随机试验所有可能结果组成的集合，记为 Ω

事件

样本空间的子集A称为事件

集合运算

古典概率

- 随机试验中一切可能结果是**有限多个**；
- 每个结果出现的**可能性是相等的**；
- 则事件A发生的概率可表示为

$$P(A) = \frac{\text{事件A所包含的样本点个数}}{\text{样本空间中所含样本点个数}}$$

问题：如果随机试验所有可能的结果为无穷多个，该如何计算事件A的概率？

- 计算**无穷个**基本事件的情形；
- 样本点具有**均匀分布**的性质；
- 设用 $L(\Omega)$ 作为区域 Ω 大小的量度，而区域 Ω 中任意可能出现的小区域 A 的量度用 $L(A)$ 表示；
- 则事件 A （或某一区域）发生的概率表示为

$$P(A) = \frac{L(A)}{L(\Omega)}$$

问题：如果事先不知道随机试验到底有多少可能的结果，又该如何计算事件 A 的概率？

统计概率

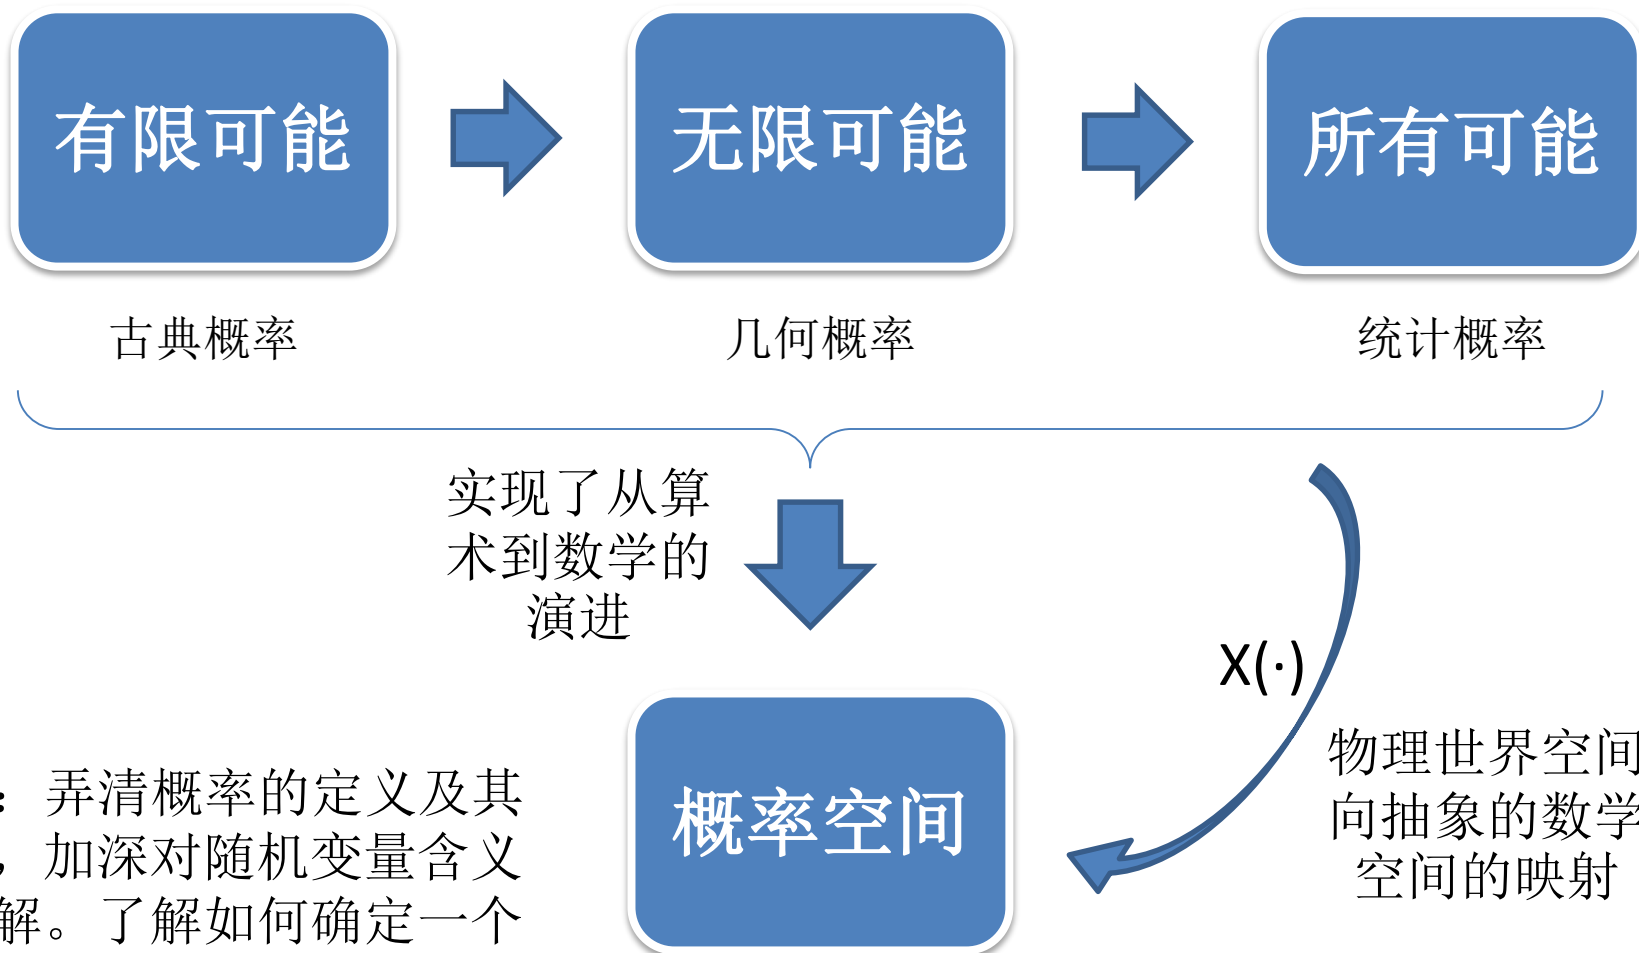
- 用于计算前两种随机概率概括不了的随机事件概率；
- 用事件的**频率**近似地去表达事件的**概率**；
- 若在同样的条件下，将随机试验独立的重复做 n 次，事件 A 出现了 n_A 次，则事件 A 的频率是

$$f_A = \frac{n_A}{n} \longrightarrow f_A \approx P(A)$$

- 当试验次数 n 增大时，其中大量的频率聚集在一个常数周围；
- 这个常数是客观存在的，反映了事件 A 出现可能性的大小，我们认为这个常数就是事件的**概率**。

(**大数定律对此结论的正确性给以了理论上的保证**)

概率论的发展



要点：弄清概率的定义及其内涵，加深对随机变量含义的理解。了解如何确定一个随机变量的概率分布。

公理化定义概率

对于一个事件 $A \in$ 样本空间 Ω ，赋予一个实数 P ，若满足：

1. $0 \leq P(A) \leq 1$;

2. $P(\Omega) = 1$;

3. 若 A_1, A_2, \dots, A_k 两两互斥，则

$$P\left(\bigcup_{k=1}^{\infty} A_k\right) = \sum_{k=1}^{\infty} P(A_k)$$

我们称 $P(A)$ 为事件 A 的一个概率。

概率空间

- 规定一个随机试验，所有样本点之集合构成样本空间 Ω ，在样本空间中一个样本点或若干个样本点之**适当集合** F 称为事件域， F 中的每一个集合称为事件。若 $A \in F$ ，则 $P(A)$ 就是事件 A 的概率，并称这三个实体的结合 (Ω, F, P) 为一个**概率空间**

条件概率

- 在事件B已发生这一条件下，事件A发生的概率。

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

- 若有N个互斥事件 $B_n(n=1,2,\dots,N)$ ，它的并集等于整个样本空间，则

$$P(A) = \sum_{i=1}^N P(A | B_i) P(B_i)$$

贝叶斯公式

- 设事件 A_1, A_2, \dots, A_n 构成一个完备事件组，概率 $P(A_i) > 0, i=1, 2, \dots, n$ ，对于任何一个事件 B ，若 $P(B) > 0$ ，有

先验概率

$$P(A_i | B) = \frac{P(A_i)P(B | A_i)}{\sum_{i=1}^N P(A_i)P(B | A_i)}$$

后验概率

事件 A_1, A_2, \dots, A_n 看作是导致事件 B 发生的“因素”， $P(A_i)$ 是在事件 B 已经出现这一信息得知前 A_i 出现的概率，通常称为**先验概率**。但是在试验中事件 B 的出现，有助于对导致事件 B 出现的各种“因素”发生的概率作进一步探讨，公式给出的 $P(A_i | B)$ 是在经过试验获得事件 B 已经发生这个信息之后，事件 A_i 发生的概率，称为**后验概率**。后验概率依赖于试验中得到的新信息的具体情况（比如事件 B 发生还是不发生），并且给出在获得新信息之后，导致 B 发生的各种因素 A_i 发生情况的新知识，因此贝叶斯公式又称为**后验概率公式或逆概率公式**

已知某种疾病的发病率是0.001。现有一种试剂可以检验患者是否得病，准确率为0.99，即在患者确实得病的情况下，它有99%的可能呈阳性。它的误报率是5%，即在患者没有得病的情况下，它有5%的可能呈现阳性。现有一个病人的检验结果为阳性，请问他确实得病的可能性有多大？

假定A表示得病，那么P(A)为0.001。这就是“先验概率”，即没有做试验之前，预计的发病率或根据历史病例统计的发病率。再假定B表示测试结果为阳性。问题就是要计算P(A|B)。这就是“后验概率”，即做了试验以后，对发病率的估计。

$$P(A|B) = \frac{P(A)P(B|A)}{P(B|A)P(A) + P(B|\bar{A})P(\bar{A})} = \frac{0.001 * 0.99}{0.99 * 0.001 + 0.05 * 0.999} = 0.019$$

问题：哪种试剂更好？
该如何下诊断结论？

另一种试剂的误报率为1%， $P(A|B_2)=0.09$

续

	试剂1 (B1)	试剂2 (B2)
第二次检测	$P(\hat{A} B1)$ $= \frac{P(\hat{A})P(B1 \hat{A})}{P(B1 \hat{A})P(\hat{A}) + P(B1 \bar{\hat{A}})P(\bar{\hat{A}})}$ $= \frac{0.019 * 0.99}{0.019 * 0.99 + 0.05 * 0.981}$ $= 0.277$	$P(\hat{A} B2)$ $= \frac{P(\hat{A})P(B2 \hat{A})}{P(B2 \hat{A})P(\hat{A}) + P(B2 \bar{\hat{A}})P(\bar{\hat{A}})}$ $= \frac{0.09 * 0.99}{0.09 * 0.99 + 0.01 * 0.91}$ $= 0.907$
更新后的 $P(\hat{A})$	$P(\hat{A}) = 0.277$	$P(\hat{A}) = 0.907$

可以相信，如果第三次测试仍然采用试剂2且检测结果为阳性，则患病的概率必将趋近于100%


但是，假设第三次仍然采用试剂1，结果仍为阳性，则患病概率约为88%，低于试剂2第二次的概率。

独立事件

- 如果A、B为两个统计独立的事件，则


$$P(A \cap B) = P(A)P(B)$$

随机变量



定义：

设 (Ω, \mathcal{F}, P) 是概率空间， $X=X(e)$ 是定义在 Ω 上的实函数，如果对任意实数 x ， $\{e: X(e) \leq x\} \in \mathcal{F}$ ，则称 $X(e)$ 是 \mathcal{F} 上的随机变量。



离散型随机变量：

只取有限个数值或可列无穷多个值。

连续型随机变量：

从原样本空间到新样本空间的映射是某一个范围，是一段（或几段）实线（也可能是整个坐标轴），随机变量可以取值于某一区间中的任一数。

概率分布函数

分布函数（一个描述随机变量取值的概率分布情况的统一方法）

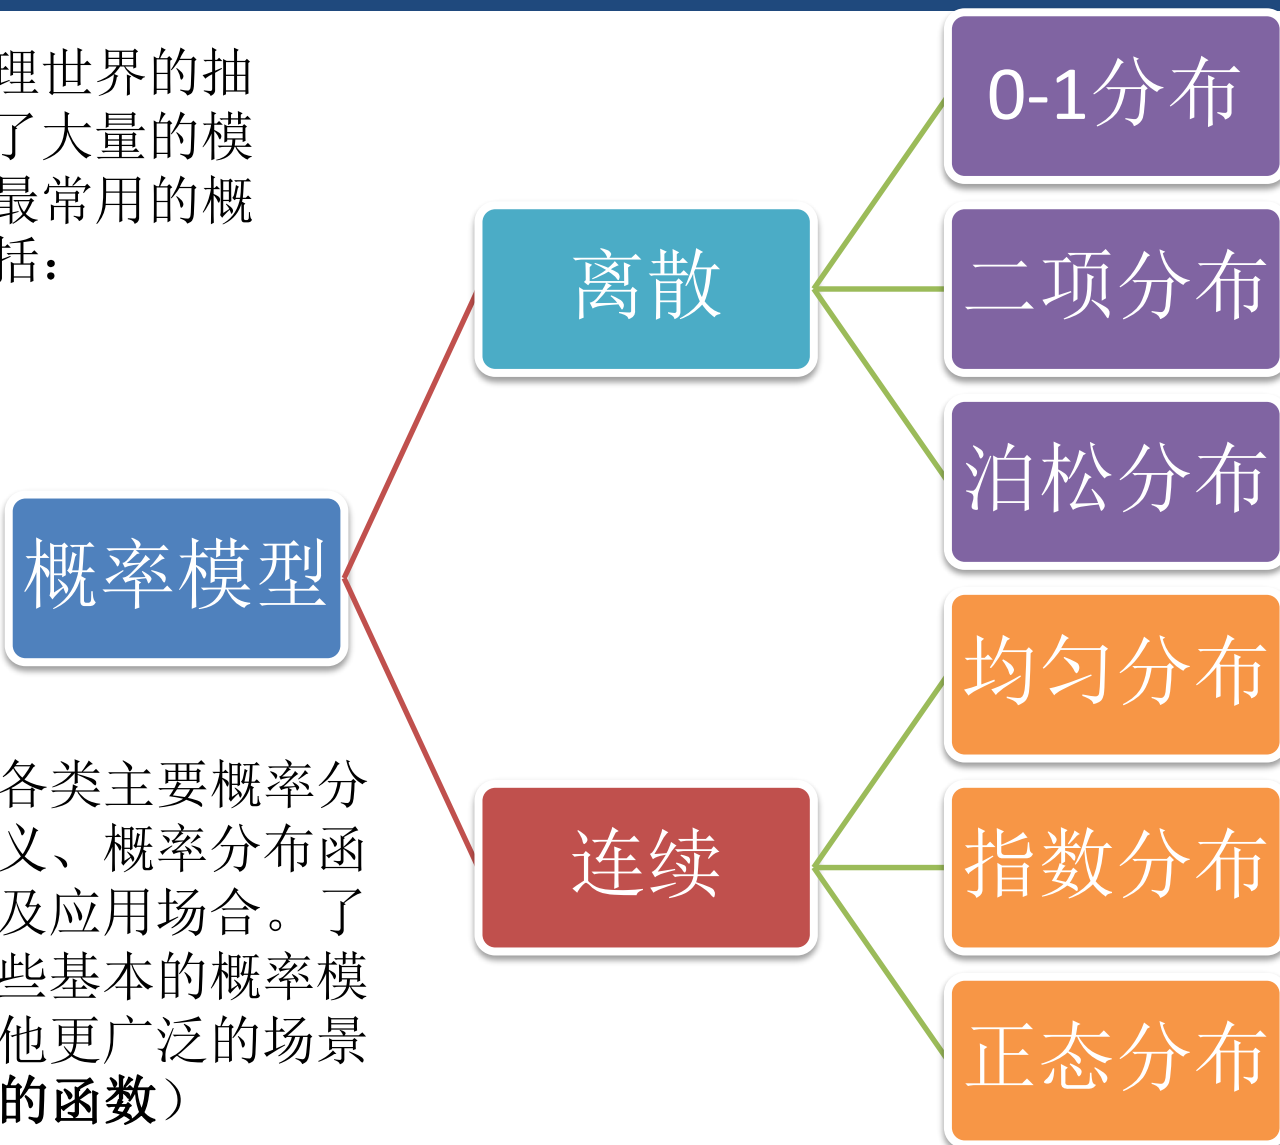
$$F(x) = P\{e : X(e) \leq x\}, -\infty < x < \infty$$

性质：

1. $F(x)$ 是非降函数；
2. $0 \leq F(x) \leq 1$ ；
3. $P\{x_1 < X \leq x_2\} = F(x_2) - F(x_1)$ ；
4. $F(x)$ 是右连续，即 $F(x+0) = F(x)$ 。

概率模型

通过对物理世界的抽象，建立了大量的模型，其中最常用的概率模型包括：



要点：理解各类主要概率分布模型的定义、概率分布函数、特性以及应用场合。了解如何从这些基本的概率模型演化到其他更广泛的场景（**随机变量的函数**）

概率分布

离散型随机变量的概率分布用分布列描述

0-1分布

$$P(X=1)=p, P(X=0)=q$$

二项分布

$$P(X=k)=C_n^k p^k q^{n-k}$$

泊松分布

$$P(X=k)=\frac{\lambda^k}{k!} e^{-\lambda}$$

连续型随机变量的概率分布用概率密度描述

均匀分布

$$f(x)=\begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{其它} \end{cases}$$

正态分布


$$f(x)=\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-a)^2}{2\sigma^2}}$$

指数分布

$$f(x)=\begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

随机变量函数的分布

在给定某任意的随机变量 X ，以及它的概率分布函数 $F_X(x)$ ，希望进一步求出给定的随机变量的某些可测函数（如 $Y=g(X)$ ）的概率分布函数。



Y 的概率分布函数公式为

$$F_Y(y) = P(x: g(x) \leq y, x \in \Omega_X)$$

如果上式右端概率的导数对于 y 处处存在，那么这个导数就给出了随机变量 Y 的概率密度

$$f_Y(y) = \frac{d}{dy} P(\{x: g(x) \leq y, x \in \Omega_X\})$$

n维随机变量及其分布函数

设 (Ω, \mathcal{F}, P) 是概率空间, $\mathbf{X}=\mathbf{X}(e)=(X_1(e), \dots, X_n(e))$ 是定义在 Ω 上的 n 维空间 \mathbb{R}^n 中取值的向量函数。如果对于任意 $\mathbf{x}=(x_1, \dots, x_n) \in \mathbb{R}^n$, $\{e: X_1(e) \leq x_1, \dots, X_n(e) \leq x_n\} \in \mathcal{F}$, 则称 $\mathbf{X}=\mathbf{X}(e)$ 为 **n维随机变量**。称

$$F(\mathbf{x}) = F(x_1, \dots, x_n) = P(e: X_1(e) \leq x_1, \dots, X_n(e) \leq x_n)$$

为 $\mathbf{X}=(X_1, X_2, \dots, X_n)$ 的 **联合分布函数**

边际分布

若二维联合分布函数中有一个变元**趋于无穷**，则其极限函数便是一维分布函数，对于这种特殊性质，我们称其为**边际分布**。

对于任意两个随机变量 X, Y ，其联合分布函数为 $F_{XY}(x, y)$ ，则

$$F_1(x) = F(x, \infty)$$

$$F_2(y) = F(\infty, y)$$

分别称 $F_1(x)$ 和 $F_2(y)$ 为 $F_{XY}(x, y)$ 关于 X 和关于 Y 的**边际分布函数**。


离散型随机变量 (X, Y) 边际分布函数计算如下

$$F_1(x) = F(x, \infty) = \lim_{y \rightarrow \infty} F_{XY}(x, y) = P(X \leq x, Y < \infty) = P(X \leq x)$$

连续型随机变量 (X, Y) 边际分布函数计算如下

$$F_2(y) = F(\infty, y) = \int_{-\infty}^{\infty} \int_{-\infty}^y f(u, v) du dv$$

相互独立的随机变量



设 X , Y 是两个随机变量, 若对任意实数 x , y 有

$$P(X \leq x, Y \leq y) = P((X \leq x) \cap (Y \leq y)) = P(X \leq x)P(Y \leq y)$$

则称 X , Y 为**相互独立的**随机变量。

若 X , Y 为相互独立随机变量, 则有

$$F_{XY}(x, y) = F_X(x)F_Y(y)$$

$$f_{XY}(x, y) = f_X(x)f_Y(y)$$

条件分布

条件概率

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

条件分布函数

$$F_{X|B}(x | B) = P(X \leq x | B) = \frac{P(X \leq x \cap B)}{P(B)}$$

$$F_{X|Y}(x | Y = y) = \frac{\int_{-\infty}^x f_{XY}(u, y) du}{f_Y(y)}$$

两边对x微分


$$f_{X|Y}(x | y) = \frac{f_{XY}(x, y)}{f_Y(y)}$$

$$F_{X|Y}(x | Y = y) = \int_{-\infty}^x f_{X|Y}(u | y) du$$

随机变量的数字特征

- 统计平均与随机变量的数学期望
- 随机变量函数的期望值
- 方差
- 协方差
- 相关系数
- 独立与不相关

随机变量的数字特征



要点： 正确理解各个数字特征的定义，以及与概率模型之间的关系

为了“拉近”现实与理论的“距离”，定义了随机变量的数字特征，简化了概率问题求解

统计平均与数学期望

设离散随机变量 X ，它可能取4个值 x_1, x_2, x_3, x_4 ，做试验 n 次，计算 X 的算术平均可得：

$$\bar{X} = \frac{1}{n}(x_1 n_1 + x_2 n_2 + x_3 n_3 + x_4 n_4) = \frac{1}{n} \sum_{k=1}^4 x_k n_k = \sum_{k=1}^4 x_k \left(\frac{n_k}{n} \right)$$

$$\longrightarrow \bar{X} = E(X) = \sum_{k=1}^{\infty} x_k P(X = x_k)$$

$P(X=x_k)$

对于离散型随机变量可以用脉冲函数来表示其概率密度

$$f_X(x) = \sum_{k=1}^{\infty} P(X = x_k) \delta(x - x_k)$$

冲激函数

随机变量数学期望定义

$$E(X) = \int_{-\infty}^{\infty} x f_X(x) dx$$

随机变量函数的期望值

已知随机变量 X 的数学期望值，求随机变量函数 $Y=g(X)$ 的数学期望，

$$E(Y) = E(g(X)) = \int_{-\infty}^{\infty} y f_Y(y) dy = \int_{-\infty}^{\infty} g(x) f_X(x) dx$$

对于多维随机变量

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{bmatrix} \quad \mathbf{Y} = g(\mathbf{X})$$

随机向量函数的数学期望

$$E(\mathbf{Y}) = \int_{-\infty}^{\infty} g(\mathbf{X}) f_X(x) dx$$

设 X_1, X_2, \dots, X_n 为随机变量，求随机变量函数 $Y = a_1 X_1 + a_2 X_2 + \dots + a_n X_n$ 的数学期望。

$$\begin{aligned} E(Y) &= E(a_1 X_1 + a_2 X_2 + \dots + a_n X_n) \\ &= E(a_1 X_1) + E(a_2 X_2) + \dots + E(a_n X_n) \\ &= a_1 E(X_1) + a_2 E(X_2) + \dots + a_n E(X_n) \end{aligned}$$

线性组合的随机变量的期望

已知随机变量 X_1 和 X_2 ，求随机变量函数 $Y=aX_1+bX_2$ 的数学期望

$$\begin{aligned} E(Y) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (ax_1 + bx_2) f_{X_1 X_2}(x_1, x_2) dx_1 dx_2 \\ &= a \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_1 f_{X_1 X_2}(x_1, x_2) dx_1 dx_2 + b \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_1 X_2}(x_1, x_2) dx_1 dx_2 \\ &= aE(X_1) + bE(X_2) \end{aligned}$$

加权求和的期望等于加权期望的和

求数学期望是线性运算

数学期望的线性运算不受独立条件限制

相互独立的随机变量的期望

已知随机变量 X_1 和 X_2 ，求随机变量函数 $Y=g_1(X_1)g_2(X_2)$ 的数学期望

$$E[Y] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g_1(x_1)g_2(x_2)f_{x_1x_2}(x_1, x_2)dx_1dx_2$$

假设两个随机变量 X_1 和 X_2 相互独立，则有

$$f_{x_1x_2}(x_1, x_2) = f_{x_1}(x_1)f_{x_2}(x_2)$$

因此，有

$$\begin{aligned} E[Y] &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g_1(x_1)g_2(x_2)f_{x_1}(x_1)f_{x_2}(x_2)dx_1dx_2 \\ &= \int_{-\infty}^{\infty} g_1(x_1)f_{x_1}(x_1)dx_1 \int_{-\infty}^{\infty} g_2(x_2)f_{x_2}(x_2)dx_2 \\ &= E[g_1(X_1)]E[g_2(X_2)] \end{aligned}$$

随机变量 X ，若 $E[X^k] < \infty$ ，称 $E[X^k]$ 为 X 的**k阶原点矩**。

离散随机变量

连续随机变量

$$E[X^k] = \sum_{i=1}^n x_i^k P(X = x_i) = \int_{-\infty}^{\infty} x^k f_X(x) dx$$

又若 $E[X]$ 存在，且 $E[|X - E[X]|^k] < \infty$ ，称

$$E[(X - E[X])^k]$$

为 X 的**k阶中心矩**。

离散随机变量

连续随机变量

$$E[(X - E[X])^k] = \sum_{i=1}^n (x_i - E[X])^k P(X = x_i) = \int_{-\infty}^{\infty} (x - E[X])^k f_X(x) dx$$

一阶原点矩就是随机变量的数学期望，

$$EX \triangleq \int_{-\infty}^{\infty} x dF(x)$$

数学期望大致的描述了概率分布的中心。

二阶中心矩就是随机变量的方差，

$$DX \stackrel{def}{=} E(X - EX)^2$$

方差反映随机变量取值的离散程度。

0—1分布

泊松分布

正态分布

数学期望和方差(见page3, 表1-1)

协方差

中心化的两个随机变量 $X-E[X]$, $Y-E[Y]$ 的互相关矩称为随机变量 X 和 Y 的协方差,

$$\begin{aligned} \text{Cov}(X, Y) &= E[(X - EX)(Y - EY)] \\ &= E(XY) - E(X)E(Y) \end{aligned}$$

协方差是描述随机现象中, 随机变量 X 和 Y 概率相关的程度。


引入一个描述两个随机变量相关程度的系数

$$\rho_{XY} \stackrel{\text{def}}{=} \frac{\text{Cov}(X, Y)}{\sqrt{DX} \sqrt{DY}}$$

ρ_{XY} 称为归一化的协方差系数或相关系数。

$$-1 \leq \rho_{XY} \leq 1$$

协方差



若 $\rho_{XY}=0$ ，则称随机变量 X 和 Y 不相关。

若两个随机变量 X 和 Y 的联合矩满足 $E[X^i Y^j] = E[X^i] E[Y^j]$

则称随机变量 X 和 Y 统计独立

不相关与独立


统计独立



不相关

$$\begin{aligned} \text{Cov}(X, Y) &= E[(X - EX)(Y - EY)] \\ &= E[XY] - E[X]E[Y] = 0 \end{aligned}$$

统计独立



不相关

特征函数

定义：设随机变量的概率密度为 $f(x)$ ，称其傅氏逆变换

$$g(t) = E(e^{itx}) = \int_{-\infty}^{\infty} e^{itx} f(x) dx$$

为 X 的特征函数。

$$\text{而 } f(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} g(t) dt$$

对于离散随机变量，

$$g(t) = \sum_{k=1}^{\infty} e^{itx_k} p_k$$

性质：（介绍）

特征函数的性质

1) $g(0) = 1, |g(t)| \leq 1, g(-t) = \overline{g(t)}$.

2) $g(t)$ 在 $(-\infty, +\infty)$ 上一致连续.

3) 若随机变量 X 的 n 阶矩 EX^n 存在, 则 X 的特征函数 $g(t)$ 可微分 n 次, 且当 $k \leq n$ 时, 有 $g^{(k)}(0) = i^k EX^k$.

4) $g(t)$ 是非负定函数, 即对任意正整数 n 及任意实数 t_1, t_2, \dots, t_n 和复数 z_1, z_2, \dots, z_n , 有

$$\sum_{k,l=1}^n g(t_k - t_l) z_k \overline{z_l} \geq 0.$$

5) 若 X_1, X_2, \dots, X_n 是相互独立的随机变量, 则 $X = X_1 + X_2 + \dots + X_n$ 的特征函数

$$g(t) = g_1(t) g_2(t) \cdots g_n(t)$$

其中 $g_i(t)$ 是随机变量 X_i 的特征函数, $i = 1, 2, \dots, n$.

6) 随机变量的分布函数由其特征函数惟一确定.

例1.1

例1.1 设 X 服从 $B(n, p)$ ，求 X 的特征函数 $g(t)$ 及 EX ， EX^2 ， DX 。
根据特征函数的定义：

$$g(t) = E[e^{itx}]$$

$\because X$ 服从二项分布 $B(n, p)$

\therefore 其分布列为： $p(X = k) = C_n^k p^k q^{n-k}$ ， $q = 1 - p$ ， $k = 0, 1, \dots, n$

$$\text{因此， } g(t) = \sum_{k=0}^n e^{itk} \cdot C_n^k p^k q^{n-k}$$

$$= \sum_{k=0}^n C_n^k (pe^{it})^k \cdot q^{n-k}$$

$$= (pe^{it} + q)^n$$

$$EX = -ig'(0) = -i \frac{d}{dt} (pe^{it} + q)^n \Big|_{t=0}$$

$$= -i \cdot n(pe^{it} + q)^{n-1} \cdot pie^{it} \Big|_{t=0} = np$$

续例1.1

$$\begin{aligned} E[X^2] &= (-i)^2 g''(0) = -g''(0) = -\frac{d^2}{dt^2} (pe^{it} + q)^n \Big|_{t=0} \\ &= -\frac{d}{dt} inp(pe^{it} + q)^{n-1} \cdot e^{it} \Big|_{t=0} \\ &= -inp(n-1)(pe^{it} + q)^{n-2} \cdot e^{it} \cdot pie^{it} \Big|_{t=0} \\ &\quad - inp \cdot (pe^{it} + q)^{n-1} \cdot ie^{it} \Big|_{t=0} \\ &= n(n-1)p^2 + np = npq + n^2p^2 \\ DX &= E[X^2] - (EX)^2 = npq + n^2p^2 - n^2p^2 = npq \end{aligned}$$

母函数

定义： 设 X 是非负整型随机变量，分布列

$$p_k = P(X = k), k = 0, 1, \dots$$

称

$$P(s) \stackrel{def}{=} E(s^X) = \sum_{k=0}^{\infty} p_k s^k$$

为 X 的母函数。

性质：（介绍）

母函数的性质

1)非负整数值随机变量的分布列由其母函数惟一确定.

2)设 $P(s)$ 是 X 的母函数, 若 EX 存在, 则

$$EX = P'(1),$$

若 DX 存在, 则

$$DX = P''(1) + P'(1) - [P'(1)]^2.$$

3)独立随机变量之和的母函数等于母函数之积.

4)若 X_1, X_2, \dots, X_n 是相互独立且同分布的非负整数值随机变量,

N 是与 X_1, X_2, \dots 独立非负整数值随机变量, 则 $Y = \sum_{k=1}^N X_k$ 的母函数

$$H(s) = G(P(s)),$$

其中 $G(s)$ 、 $P(s)$ 分别是 N 、 X_1 的母函数.

小节

概率论中的基本概念——随机试验、样本空间、事件、概率、概率空间、条件概率、全概率。

随机变量及分布函数——随机变量、分布函数、随机变量函数的分布、 n 维随机变量、边际分布、条件分布。

随机变量的数字特征——统计平均、数学期望、方差、协方差、相关系数、相关性和统计独立。

作业

- 复习概率论与数理统计方面的知识。